BÁO CÁO THỰC HÀNH LAB 1: DỰ ĐOÁN GIÁ NHÀ BẰNG HỒI QUY TUYẾN TÍNH

Họ và tên: Trần Trung Hiếu
Mã sinh viên: 24122033
Lớp: 24TNT1

Ngày 5 tháng 4 năm 2026

Mục lục

1 Tổng quan Bài toán **2**

2 Phân tích Khám phá Dữ liệu (Exploratory Data Analysis - EDA) **2**
2.1 Phân phối của biến mục tiêu (`SalePrice`) 2
2.2 Phân tích Tương quan và Lựa chọn Đặc trưng 3
2.3 Đánh giá chi tiết các Đặc trưng Quan trọng nhất 4

3 Tiền xử lý và Chuẩn bị dữ liệu **5**
3.1 Thống kê và Xử lý giá trị thiếu (Missing Values) 5
3.2 Mã hóa và Tạo Ma trận Thiết kế 6

4 Cơ sở Lý thuyết Mô hình hóa **7**
4.1 Hệ phương trình chuẩn (Normal Equation) 7
4.2 Kiểm chứng chéo (K-Fold Cross-Validation) 7

5 Triển khai chi tiết và Kết quả **7**
5.1 Yêu cầu 2a: Mô hình hồi quy đa biến toàn diện 7
5.2 Yêu cầu 2b: Mô hình với đặc trưng đơn lẻ tốt nhất 10
5.3 Yêu cầu 2c: Kỹ thuật thiết kế đặc trưng (Feature Engineering) 11
5.3.1 Phương án 1: Biến đổi Logarit (Log Transformation) 11
5.3.2 Phương án 2: Tổng hợp Đặc trưng (Domain Knowledge) 11
5.3.3 Phương án 3: Tương tác và Phi tuyến (Polynomial) 11

6 Kết luận Tổng thể **12**

1 Tổng quan Bài toán

Mục tiêu của bài toán là xây dựng các mô hình Học máy (Machine Learning) sử dụng thuật toán Hồi quy tuyến tính (Linear Regression) nhằm dự đoán giá trị bất động sản (`SalePrice`) dựa trên tập dữ liệu nhà ở (Ames Housing Dataset). Điểm đặc biệt của báo cáo này là toàn bộ quá trình huấn luyện mô hình được triển khai từ đầu (from scratch) thông qua các phép toán Đại số tuyến tính trên thư viện `NumPy`, không sử dụng các thư viện tự động như `scikit-learn`.

2 Phân tích Khám phá Dữ liệu (Exploratory Data Analysis - EDA)

Trước khi xây dựng mô hình, dữ liệu đã được khám phá để hiểu rõ các đặc tính thống kê và mối quan hệ giữa các biến.

2.1 Phân phối của biến mục tiêu (`SalePrice`)

Biến mục tiêu `SalePrice` là yếu tố quan trọng nhất cần dự đoán. Biểu đồ dưới đây thể hiện sự phân bố giá trị của các căn nhà trong tập dữ liệu.

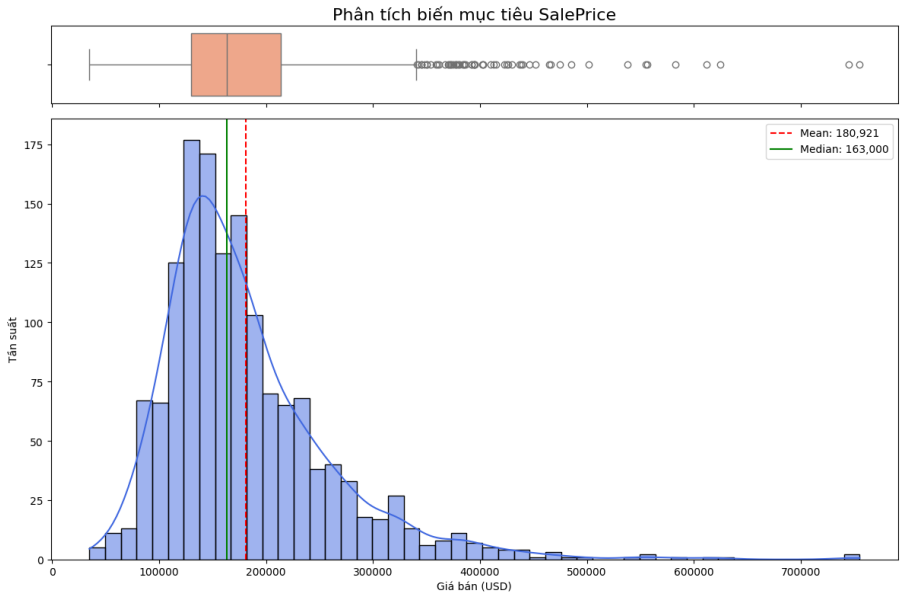

Hình 1: Phân tích phân phối của biến mục tiêu SalePrice.

Nhận xét: Dựa vào Hình 1, có thể thấy `SalePrice` thể hiện phân phối lệch phải (right-skewed). Phần lớn các ngôi nhà tập trung ở phân khúc giá từ $100,000$ đến $200,000$ USD. Tuy nhiên, phần đuôi đồ thị kéo dài về phía phải cho thấy sự tồn tại của một lượng nhỏ các căn nhà có giá trị cực kỳ cao (Outliers, lên tới $700,000$ USD). Sự lệch này gợi ý rằng việc áp dụng phép biến đổi Logarit lên biến mục tiêu (ở phần Feature Engineering)

là cần thiết để đưa phân phối về dạng chuẩn (Normal Distribution), giúp mô hình tuyến tính dự đoán ổn định hơn.

2.2 Phân tích Tương quan và Lựa chọn Đặc trưng

Để tìm ra các yếu tố ảnh hưởng mạnh nhất đến giá nhà, ma trận tương quan (Correlation Matrix) đã được tính toán và trực quan hóa thông qua biểu đồ Heatmap.

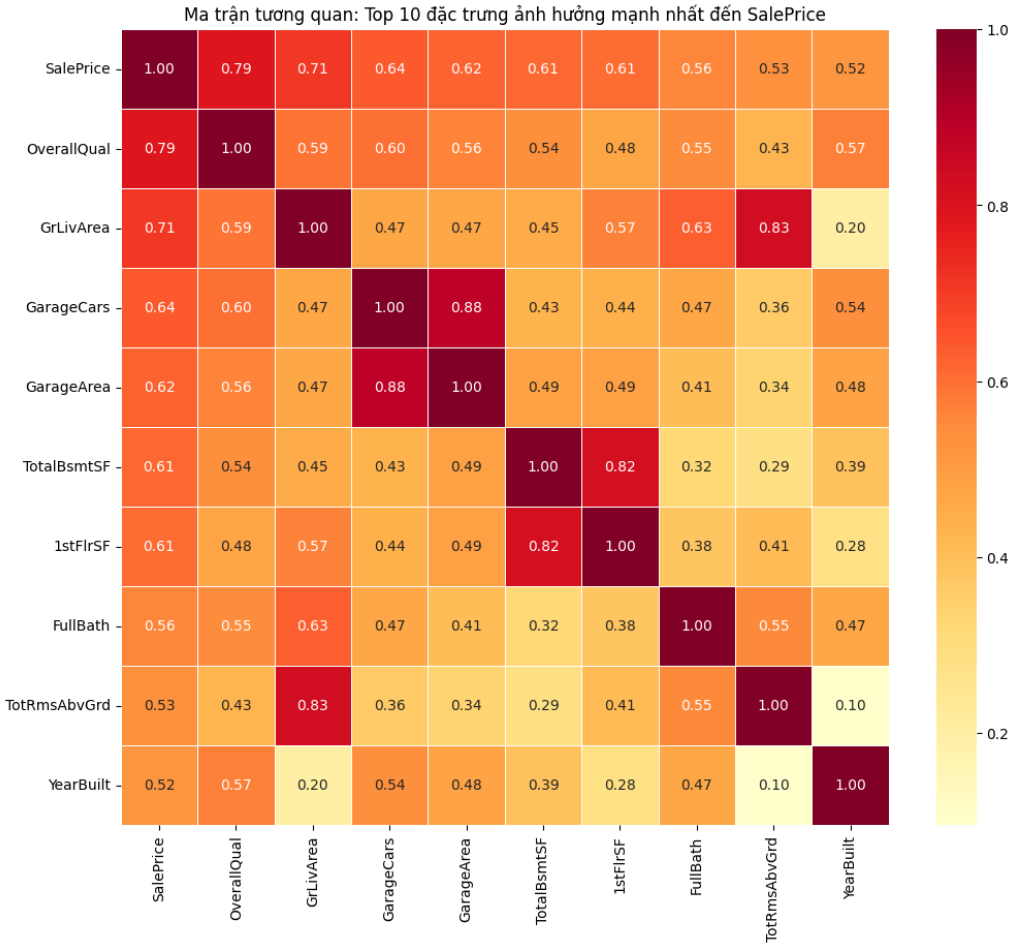

Hình 2: Heatmap ma trận tương quan giữa các đặc trưng số học và SalePrice.

Nhận xét: Dựa vào biểu đồ nhiệt (Hình 2), ta có thể rút ra 5 đặc trưng có mối tương quan tuyến tính chặt chẽ nhất với `SalePrice` bao gồm:

1. `OverallQual` (Chất lượng tổng thể): Tương quan cao nhất (~ 0.79).
2. `GrLivArea` (Diện tích sống): Tương quan ~ 0.71.
3. `GarageCars` (Sức chứa Gara): Tương quan ~ 0.64.
4. `TotalBsmtSF` (Diện tích tầng hầm): Tương quan ~ 0.61.
5. `1stFlrSF` (Diện tích tầng 1): Tương quan ~ 0.60.

Ngoài ra, Heatmap cũng bộc lộ rõ hiện tượng **đa cộng tuyến (Multicollinearity)** giữa các biến độc lập. Ví dụ, `GarageCars` và `GarageArea` có sự tương quan cực kỳ cao, tương tự là cặp `GrLivArea` và `TotRmsAbvGrd` (Tổng số phòng). Điều này báo hiệu việc cần phải cẩn trọng hoặc tạo ra các biến tổng hợp khi thiết kế mô hình.

2.3 Đánh giá chi tiết các Đặc trưng Quan trọng nhất

Để hiểu rõ hơn bản chất của dữ liệu, hai biến có sức mạnh dự đoán cao nhất (`GrLivArea` và `OverallQual`) được phân tích sâu hơn.

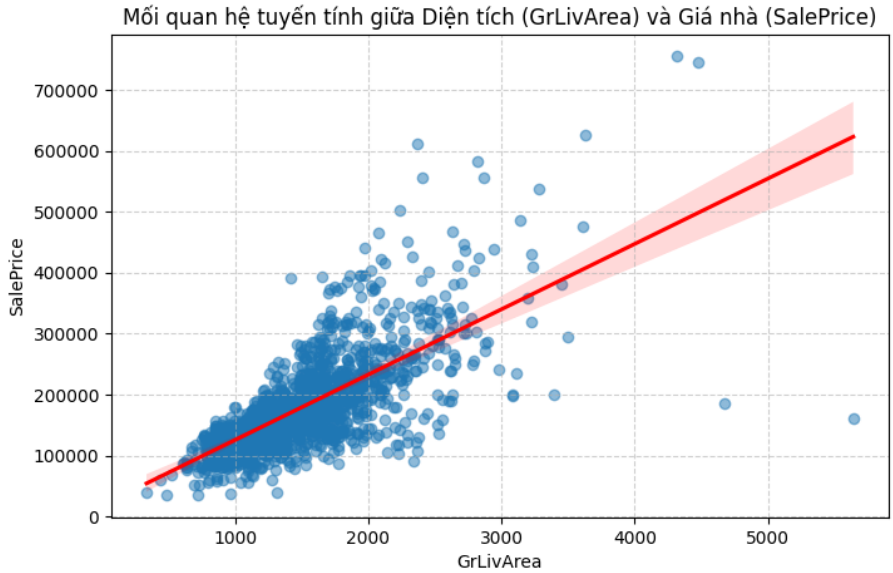

Hình 3: Mối quan hệ tuyến tính giữa diện tích sinh hoạt (GrLivArea) và SalePrice.

Nhận xét biểu đồ Diện tích: Hình 3 cho thấy một xu hướng tuyến tính thuận rất rõ ràng: diện tích càng lớn thì giá nhà càng cao. Tuy nhiên, sự phân tán (variance) có dấu hiệu mở rộng ở phần diện tích lớn. Đặc biệt, xuất hiện một vài điểm dữ liệu ngoại lai (outliers) có diện tích cực lớn (hơn 4000 sqft) nhưng giá lại rất thấp. Các điểm này có thể làm chệch đường hồi quy và gây sai số lớn.

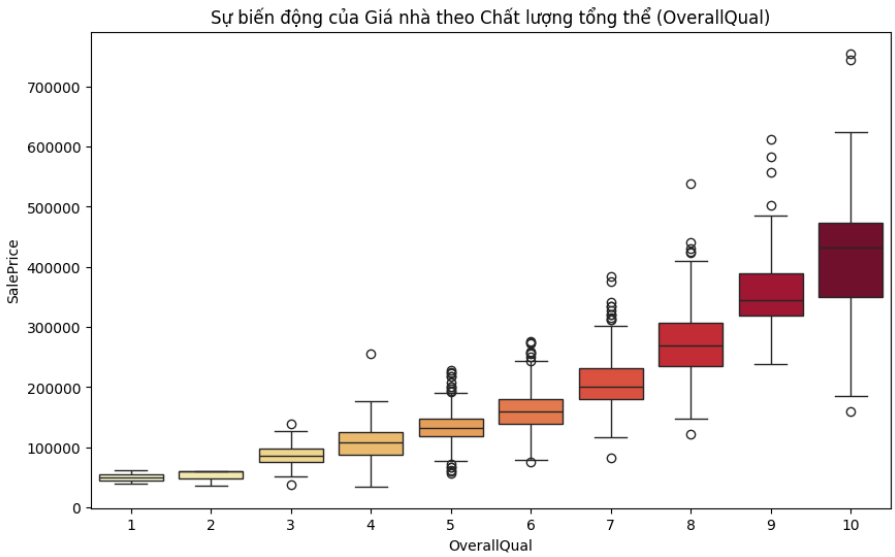

Hình 4: Sự biến động của giá nhà theo mức độ chất lượng tổng thể (OverallQual).

Nhận xét biểu đồ Chất lượng: Hình 4 mang lại góc nhìn thú vị. Mối quan hệ giữa chất lượng nhà và giá không đơn thuần là tuyến tính mà có xu hướng **hàm mũ (exponential)**. Khi điểm chất lượng tăng từ 1 đến 5, giá nhà tăng khá chậm. Tuy nhiên, khi chất lượng đạt các mức cao (từ 8 đến 10), giá nhà tăng vọt theo cấp số nhân và độ dao động giá tại các mức này cũng cực kỳ lớn. Phát hiện này là tiền đề quan trọng cho việc đề xuất **Mô hình Đa thức (Polynomial)** ở phần sau.

3 Tiền xử lý và Chuẩn bị dữ liệu

Trước khi huấn luyện mô hình, dữ liệu thô được làm sạch và chuẩn hóa qua các bước khắt khe.

3.1 Thống kê và Xử lý giá trị thiếu (Missing Values)

Trong tập dữ liệu Ames Housing, việc xuất hiện các giá trị khuyết thiếu (`NA`) thường mang ý nghĩa thông tin quan trọng thay vì chỉ đơn thuần là dữ liệu bị mất. Biểu đồ dưới đây thống kê các đặc trưng có lượng giá trị khuyết lớn nhất.

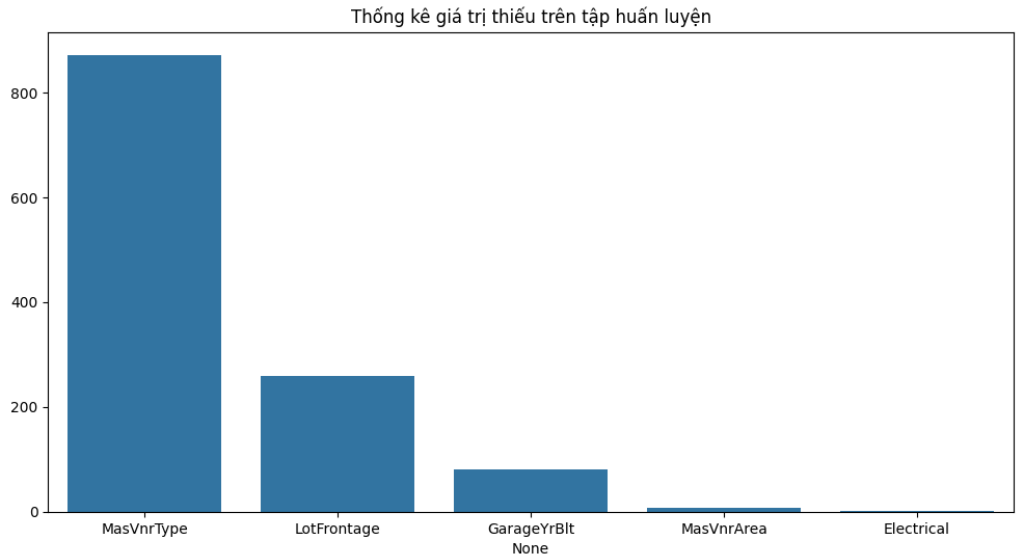

Hình 5: Thống kê lượng giá trị thiếu (Missing values) trên tập huấn luyện.

Nhận xét và Chiến lược xử lý: Dựa vào Hình 5, ta thấy các biến như `PoolQC`, `MiscFeature`, `Alley` có tỷ lệ khuyết dữ liệu cực cao. Tuy nhiên, theo mô tả của bộ dữ liệu, `NA` ở đây không phải là lỗi hệ thống mà đại diện cho việc **không tồn tại** tiện ích đó (ví dụ: `NA` tại `PoolQC` nghĩa là ngôi nhà "Không có hồ bơi").

Để phản ánh chính xác bản chất định tính này và tránh việc các hàm xử lý dữ liệu mặc định loại bỏ các dòng hữu ích, chiến lược xử lý được thực hiện như sau:

- **Chuyển đổi thành lớp dữ liệu mới:** Đối với danh sách các đặc trưng về tiện ích (như `PoolQC`, `Alley`, `GarageType`, `BsmtQual`,...), các giá trị khuyết được điền bằng chuỗi **'None'** thông qua hàm `fillna('None')`.

- **Ý nghĩa kỹ thuật:** Việc chuyển `NA` thành một nhãn cụ thể là `'None'` giúp giữ lại thông tin về sự vắng mặt của tiện ích dưới dạng một phân loại hợp lệ. Khi thực hiện One-Hot Encoding ở bước sau, nhãn này sẽ được chuyển thành một cột đặc trưng riêng biệt, giúp mô hình hồi quy hiểu được giá trị khác biệt giữa một ngôi nhà có tiện ích và một ngôi nhà không có tiện ích.

3.2 Mã hóa và Tạo Ma trận Thiết kế

- **Mã hóa phân loại (One-Hot Encoding):** Các biến danh mục (categorical variables) được chuyển đổi thành các vector nhị phân (0 và 1) bằng hàm `pd.get_dummies()` để đưa vào ma trận tính toán.

- **Chuẩn bị ma trận thiết kế (Design Matrix):** Một cột vector chứa toàn giá trị 1 được chèn vào vị trí đầu tiên của ma trận X để đại diện cho hệ số chặn (Bias, θ_0). Phương trình hồi quy tổng quát được viết gọn thành $y = X\theta$.

4 Cơ sở Lý thuyết Mô hình hóa

4.1 Hệ phương trình chuẩn (Normal Equation)

Trọng số tối ưu θ được tìm bằng công thức giải tích đóng:

$$\theta = (X^T X)^{-1} X^T y \tag{1}$$

Trong code, hàm `np.linalg.pinv()` (Ma trận giả nghịch đảo Moore-Penrose) được sử dụng để khắc phục rủi ro ma trận $(X^T X)$ không khả nghịch (Singular Matrix) do đa cộng tuyến gây ra.

4.2 Kiểm chứng chéo (K-Fold Cross-Validation)

Kỹ thuật 5-Fold Cross-Validation được sử dụng. Dữ liệu huấn luyện được xáo trộn ngẫu nhiên (chốt seed để đảm bảo tái lập) và chia làm 5 phần (folds) bằng nhau. Việc này giúp đánh giá khách quan năng lực khái quát hóa của mô hình, tránh hiện tượng quá khớp (Overfitting). Sai số dùng để đánh giá là **MAE (Mean Absolute Error)**.

5 Triển khai chi tiết và Kết quả

5.1 Yêu cầu 2a: Mô hình hồi quy đa biến toàn diện

Tiếp cận: Đưa toàn bộ các đặc trưng sẵn có (kể cả các cột tạo ra từ One-Hot Encoding) vào ma trận huấn luyện.
Nhận xét kết quả:

- **Ưu điểm:** Cung cấp cho thuật toán lượng thông tin tối đa, giúp bắt được mọi đặc tính của tập huấn luyện.
- **Nhược điểm:** Ma trận thiết kế phình to dẫn đến tốc độ tính toán bị ảnh hưởng. Sự xuất hiện của hàng loạt các trọng số âm vô lý ở một số biến là dấu hiệu rõ ràng của hiện tượng đa cộng tuyến. Mô hình khó giải thích cho người không có chuyên môn.

Công thức hồi quy rút gọn (với ký hiệu viết tắt):

$$\begin{aligned}
\text{SalePrice} = &-22513.679 \\
&+ 8.063 \cdot \text{LF} + 0.711 \cdot \text{LA} + 6574.461 \cdot \text{OQ} + 5835.106 \cdot \text{OC1} + 331.825 \cdot \text{YB} \\
&+ 101.976 \cdot \text{YRA} + 21.681 \cdot \text{MVA} + 19.066 \cdot \text{BFS1} + 12.688 \cdot \text{BFS2} + 1.286 \cdot \text{BUS} \\
&+ 20.070 \cdot \text{TBS} + 5.439 \cdot \text{1S} + 22.429 \cdot \text{2S} - 42.660 \cdot \text{LQF} + 38.822 \cdot \text{GA} \\
&+ 1572.325 \cdot \text{BFB} - 395.058 \cdot \text{BHB} + 3857.492 \cdot \text{FB} + 1673.675 \cdot \text{HB} - 3242.149 \cdot \text{BA} \\
&- 11297.414 \cdot \text{KA} + 1807.198 \cdot \text{TRA} + 6155.401 \cdot \text{FP} - 28.701 \cdot \text{GYB} + 4053.906 \cdot \text{GC}
\end{aligned}$$

$$
\begin{aligned}
&+ 18.776 \cdot \mathrm{GA2} + 15.173 \cdot \mathrm{WDS} + 1.165 \cdot \mathrm{OPS} + 4.444 \cdot \mathrm{EP} + 34.846 \cdot \mathrm{3SP} \\
&+ 35.831 \cdot \mathrm{SP} + 657.337 \cdot \mathrm{PA} + 0.137 \cdot \mathrm{MV} - 486.429 \cdot \mathrm{MS} - 491.095 \cdot \mathrm{YS} \\
&- 6420.290 \cdot \mathrm{MSC}_{120} - 3526.741 \cdot \mathrm{MSC}_{160} - 10051.125 \cdot \mathrm{MSC}_{180} + 5257.730 \cdot \mathrm{MSC}_{190} \\
&+ 3343.350 \cdot \mathrm{MSC}_{20} + 6315.364 \cdot \mathrm{MSC}_{30} - 1267.866 \cdot \mathrm{MSC}_{40} - 993.499 \cdot \mathrm{MSC}_{45} \\
&+ 1283.748 \cdot \mathrm{MSC}_{50} + 7968.604 \cdot \mathrm{MSC}_{60} + 10076.220 \cdot \mathrm{MSC}_{70} - 13687.154 \cdot \mathrm{MSC}_{75} \\
&- 7439.175 \cdot \mathrm{MSC}_{80} - 10670.973 \cdot \mathrm{MSC}_{85} - 2726.308 \cdot \mathrm{MSC}_{90} - 26084.494 \cdot \mathrm{MZ}_{C} \\
&+ 8015.244 \cdot \mathrm{MZ}_{FV} - 2511.076 \cdot \mathrm{MZ}_{RH} + 677.284 \cdot \mathrm{MZ}_{RL} - 2635.078 \cdot \mathrm{MZ}_{RM} \\
&- 27538.185 \cdot \mathrm{ST}_{Grvl} + 5000.073 \cdot \mathrm{ST}_{Pave} - 6785.701 \cdot \mathrm{AL}_{Grvl} - 8361.583 \cdot \mathrm{AL}_{None} \\
&- 7390.817 \cdot \mathrm{AL}_{Pave} - 8761.345 \cdot \mathrm{LS}_{IR1} - 3939.232 \cdot \mathrm{LS}_{IR2} - 2837.356 \cdot \mathrm{LS}_{IR3} \\
&- 7000.186 \cdot \mathrm{LS}_{Reg} - 6560.913 \cdot \mathrm{LC1}_{Bnk} + 1832.643 \cdot \mathrm{LC1}_{HLS} - 16796.669 \cdot \mathrm{LC1}_{Low} \\
&- 1013.170 \cdot \mathrm{LC1}_{Lvl} + 10755.270 \cdot \mathrm{UT}_{AllPub} - 33293.381 \cdot \mathrm{UT}_{NoSeWa} - 789.944 \cdot \mathrm{LC2}_{Corner} \\
&+ 7242.008 \cdot \mathrm{LC2}_{CulDSac} - 8321.424 \cdot \mathrm{LC2}_{FR2} - 18109.922 \cdot \mathrm{LC2}_{FR3} - 2558.841 \cdot \mathrm{LC2}_{Inside} \\
&+ 4134.046 \cdot \mathrm{LS2}_{Gtl} + 11889.548 \cdot \mathrm{LS2}_{Mod} - 38561.703 \cdot \mathrm{LS2}_{Sev} + 2708.123 \cdot \mathrm{NH}_{Blmngtn} \\
&+ 11140.778 \cdot \mathrm{NH}_{Blueste} + 696.328 \cdot \mathrm{NH}_{BrDale} - 4626.117 \cdot \mathrm{NH}_{BrkSide} - 12567.853 \cdot \mathrm{NH}_{ClearCr} \\
&- 7917.342 \cdot \mathrm{NH}_{CollgCr} + 12915.766 \cdot \mathrm{NH}_{Crawfor} - 19528.306 \cdot \mathrm{NH}_{Edwards} - 9055.205 \cdot \mathrm{NH}_{Gilbert} \\
&- 10802.956 \cdot \mathrm{NH}_{IDOTRR} - 7036.686 \cdot \mathrm{NH}_{MeadowV} - 18693.003 \cdot \mathrm{NH}_{Mitchel} - 14929.450 \cdot \mathrm{NH}_{NAmes} \\
&+ 16017.765 \cdot \mathrm{NH}_{NPkVill} - 15368.224 \cdot \mathrm{NH}_{NWAmes} + 27025.667 \cdot \mathrm{NH}_{NoRidge} + 20399.105 \cdot \mathrm{NH}_{Nridg} \\
&- 12918.231 \cdot \mathrm{NH}_{OldTown} - 6812.978 \cdot \mathrm{NH}_{SWISU} - 8716.517 \cdot \mathrm{NH}_{Sawyer} - 646.744 \cdot \mathrm{NH}_{SawyerW} \\
&- 13.297 \cdot \mathrm{NH}_{Somerst} + 41612.539 \cdot \mathrm{NH}_{StoneBr} - 7825.608 \cdot \mathrm{NH}_{Timber} + 2404.337 \cdot \mathrm{NH}_{Veenker} \\
&- 8753.860 \cdot \mathrm{C1}_{Artery} - 1709.473 \cdot \mathrm{C1}_{Feedr} + 7916.906 \cdot \mathrm{C1}_{Norm} + 2074.337 \cdot \mathrm{C1}_{PosA} \\
&+ 6427.500 \cdot \mathrm{C1}_{PosN} - 24157.981 \cdot \mathrm{C1}_{RRAe} + 4605.083 \cdot \mathrm{C1}_{RRAn} - 12662.936 \cdot \mathrm{C1}_{RRNe} \\
&+ 3722.307 \cdot \mathrm{C1}_{RRNn} + 43541.537 \cdot \mathrm{C2}_{Artery} + 38381.781 \cdot \mathrm{C2}_{Feedr} + 32442.764 \cdot \mathrm{C2}_{Norm} \\
&+ 91607.082 \cdot \mathrm{C2}_{PosA} - 195323.134 \cdot \mathrm{C2}_{PosN} - 93175.220 \cdot \mathrm{C2}_{RRAe} + 20413.783 \cdot \mathrm{C2}_{RRAn} \\
&+ 39573.298 \cdot \mathrm{C2}_{RRNn} + 4994.027 \cdot \mathrm{BT}_{1Fam} - 9423.974 \cdot \mathrm{BT}_{2fmCon} - 2726.307 \cdot \mathrm{BT}_{Duplex} \\
&- 9932.236 \cdot \mathrm{BT}_{Twnhs} - 5449.632 \cdot \mathrm{BT}_{TwnhsE} - 4274.252 \cdot \mathrm{HS}_{1.5Fin} + 9534.142 \cdot \mathrm{HS}_{1.5Unf} \\
&- 1006.796 \cdot \mathrm{HS}_{1Story} - 12506.826 \cdot \mathrm{HS}_{2.5Fin} - 2926.609 \cdot \mathrm{HS}_{2.5Unf} - 17654.726 \cdot \mathrm{HS}_{2Story} \\
&+ 1786.159 \cdot \mathrm{HS}_{SFoyer} + 4510.792 \cdot \mathrm{HS}_{SLvl} - 30142.497 \cdot \mathrm{RS}_{Flat} - 20649.107 \cdot \mathrm{RS}_{Gable} \\
&- 18230.863 \cdot \mathrm{RS}_{Gambrel} - 21043.229 \cdot \mathrm{RS}_{Hip} - 8882.070 \cdot \mathrm{RS}_{Mansard} + 76409.658 \cdot \mathrm{RS}_{Shed} \\
&- 531502.258 \cdot \mathrm{RM}_{ClyTile} + 43381.185 \cdot \mathrm{RM}_{CompShg} + 140593.464 \cdot \mathrm{RM}_{Membran} \\
&+ 109013.991 \cdot \mathrm{RM}_{Metal} + 38396.897 \cdot \mathrm{RM}_{Roll} + 45218.722 \cdot \mathrm{RM}_{Tar\&Grv} + 34371.635 \cdot \mathrm{RM}_{WdShake} \\
&+ 97988.250 \cdot \mathrm{RM}_{WdShngl} + 6606.748 \cdot \mathrm{E1}_{AsbShng} - 16382.638 \cdot \mathrm{E1}_{AsphShn} + 6535.982 \cdot \mathrm{E1}_{BrkComm} \\
&+ 15875.778 \cdot \mathrm{E1}_{BrkFace} - 4975.244 \cdot \mathrm{E1}_{CBlock} - 5132.156 \cdot \mathrm{E1}_{CemntBd} - 5228.042 \cdot \mathrm{E1}_{HdBoard} \\
&- 11818.210 \cdot \mathrm{E1}_{ImStucc} + 2985.979 \cdot \mathrm{E1}_{MetalSd} - 6018.102 \cdot \mathrm{E1}_{Plywood} + 8293.543 \cdot \mathrm{E1}_{Stone} \\
&+ 71.305 \cdot \mathrm{E1}_{Stucco} - 5319.380 \cdot \mathrm{E1}_{VinylSd} - 5964.111 \cdot \mathrm{E1}_{Wd_Sdng} - 2069.574 \cdot \mathrm{E1}_{WdShing} \\
&- 4774.010 \cdot \mathrm{E2}_{AsbShng} + 4974.037 \cdot \mathrm{E2}_{AsphShn} - 976.827 \cdot \mathrm{E2}_{Brk_Cmn} - 2403.694 \cdot \mathrm{E2}_{BrkFace} \\
&- 4975.244 \cdot \mathrm{E2}_{CBlock} + 7498.998 \cdot \mathrm{E2}_{CmentBd} + 2114.866 \cdot \mathrm{E2}_{HdBoard} + 9150.021 \cdot \mathrm{E2}_{ImStucc}
\end{aligned}
$$

$$
\begin{aligned}
&- 1329.494 \cdot \mathrm{E2}_{MetalSd} - 25487.519 \cdot \mathrm{E2}_{Other} + 456.374 \cdot \mathrm{E2}_{Plywood} - 16858.194 \cdot \mathrm{E2}_{Stone} \\
&- 766.856 \cdot \mathrm{E2}_{Stucco} + 5892.184 \cdot \mathrm{E2}_{VinylSd} + 5672.204 \cdot \mathrm{E2}_{Wd_Sdng} - 724.959 \cdot \mathrm{E2}_{Wd_Shng} \\
&- 10983.336 \cdot \mathrm{MVT}_{BrkCmn} - 6576.011 \cdot \mathrm{MVT}_{BrkFace} - 3423.466 \cdot \mathrm{MVT}_{None} - 1555.305 \cdot \mathrm{MVT}_{Ston} \\
&+ 7104.216 \cdot \mathrm{EQ}_{Ex} - 2239.909 \cdot \mathrm{EQ}_{Fa} - 13937.260 \cdot \mathrm{EQ}_{Gd} - 13465.176 \cdot \mathrm{EQ}_{TA} \\
&- 2890.141 \cdot \mathrm{EC}_{Ex} - 5265.352 \cdot \mathrm{EC}_{Fa} - 10244.603 \cdot \mathrm{EC}_{Gd} + 2990.405 \cdot \mathrm{EC}_{Po} \\
&- 7128.421 \cdot \mathrm{EC}_{TA} - 1408.797 \cdot \mathrm{FD}_{BrkTil} + 2540.495 \cdot \mathrm{FD}_{CBlock} + 3516.489 \cdot \mathrm{FD}_{PConc} \\
&- 7396.875 \cdot \mathrm{FD}_{Slab} + 7207.322 \cdot \mathrm{FD}_{Stone} - 26996.753 \cdot \mathrm{FD}_{Wood} + 3610.797 \cdot \mathrm{BQ}_{Ex} \\
&- 6912.939 \cdot \mathrm{BQ}_{Fa} - 14012.806 \cdot \mathrm{BQ}_{Gd} + 4885.829 \cdot \mathrm{BQ}_{None} - 10108.991 \cdot \mathrm{BQ}_{TA} \\
&- 24819.914 \cdot \mathrm{BC}_{Fa} - 23826.484 \cdot \mathrm{BC}_{Gd} + 4885.828 \cdot \mathrm{BC}_{None} + 42375.888 \cdot \mathrm{BC}_{Po} \\
&- 21153.439 \cdot \mathrm{BC}_{TA} - 3206.820 \cdot \mathrm{BE}_{Av} + 10849.548 \cdot \mathrm{BE}_{Gd} - 6817.208 \cdot \mathrm{BE}_{Mn} \\
&- 8561.084 \cdot \mathrm{BE}_{No} - 14802.564 \cdot \mathrm{BE}_{None} - 6002.668 \cdot \mathrm{BFT1}_{ALQ} - 3038.218 \cdot \mathrm{BFT1}_{BLQ} \\
&- 322.230 \cdot \mathrm{BFT1}_{GLQ} - 9253.025 \cdot \mathrm{BFT1}_{LwQ} + 4885.829 \cdot \mathrm{BFT1}_{None} - 5855.823 \cdot \mathrm{BFT1}_{Rec} \\
&- 2951.981 \cdot \mathrm{BFT1}_{Unf} + 7753.612 \cdot \mathrm{BFT2}_{ALQ} - 5261.370 \cdot \mathrm{BFT2}_{BLQ} + 4773.697 \cdot \mathrm{BFT2}_{GLQ} \\
&- 5944.248 \cdot \mathrm{BFT2}_{LwQ} - 21778.797 \cdot \mathrm{BFT2}_{None} - 2079.571 \cdot \mathrm{BFT2}_{Rec} - 1.473 \cdot \mathrm{BFT2}_{Unf} \\
&- 7168.492 \cdot \mathrm{HT}_{Floor} + 31.054 \cdot \mathrm{HT}_{GasA} - 3293.883 \cdot \mathrm{HT}_{GasW} - 8069.597 \cdot \mathrm{HT}_{Grav} \\
&- 16663.568 \cdot \mathrm{HT}_{OthW} + 12626.376 \cdot \mathrm{HT}_{Wall} - 3514.366 \cdot \mathrm{HQ}_{Ex} - 3638.454 \cdot \mathrm{HQ}_{Fa} \\
&- 7240.023 \cdot \mathrm{HQ}_{Gd} - 1511.739 \cdot \mathrm{HQ}_{Po} - 6633.515 \cdot \mathrm{HQ}_{TA} - 10815.811 \cdot \mathrm{CA}_{N} \\
&- 11722.278 \cdot \mathrm{CA}_{Y} + 3966.329 \cdot \mathrm{EL}_{FuseA} + 3348.072 \cdot \mathrm{EL}_{FuseF} - 4885.204 \cdot \mathrm{EL}_{FuseP} \\
&- 42309.911 \cdot \mathrm{EL}_{Mix} + 15509.332 \cdot \mathrm{EL}_{None} + 1833.258 \cdot \mathrm{EL}_{SBrkr} + 10952.007 \cdot \mathrm{KQ}_{Ex} \\
&- 9031.905 \cdot \mathrm{KQ}_{Fa} - 12596.974 \cdot \mathrm{KQ}_{Gd} - 11861.238 \cdot \mathrm{KQ}_{TA} - 557.332 \cdot \mathrm{FN}_{Maj1} \\
&- 3140.419 \cdot \mathrm{FN}_{Maj2} + 5263.000 \cdot \mathrm{FN}_{Min1} + 8286.265 \cdot \mathrm{FN}_{Min2} - 7006.802 \cdot \mathrm{FN}_{Mod} \\
&- 42607.803 \cdot \mathrm{FN}_{Sev} + 17224.956 \cdot \mathrm{FN}_{Typ} - 7344.245 \cdot \mathrm{FQ}_{Ex} - 9502.925 \cdot \mathrm{FQ}_{Fa} \\
&- 5642.354 \cdot \mathrm{FQ}_{Gd} + 318.031 \cdot \mathrm{FQ}_{None} + 4127.745 \cdot \mathrm{FQ}_{Po} - 4494.371 \cdot \mathrm{FQ}_{TA} \\
&- 20178.831 \cdot \mathrm{GT}_{2Types} - 568.552 \cdot \mathrm{GT}_{Attchd} + 3432.576 \cdot \mathrm{GT}_{Basment} - 605.584 \cdot \mathrm{GT}_{BuiltIn} \\
&+ 5256.170 \cdot \mathrm{GT}_{CarPort} + 2599.906 \cdot \mathrm{GT}_{Detchd} - 12473.781 \cdot \mathrm{GT}_{None} - 2519.246 \cdot \mathrm{GF}_{Fin} \\
&- 12473.780 \cdot \mathrm{GF}_{None} - 4726.386 \cdot \mathrm{GF}_{RFn} - 2818.696 \cdot \mathrm{GF}_{Unf} + 104866.571 \cdot \mathrm{GQ}_{Ex} \\
&- 28380.491 \cdot \mathrm{GQ}_{Fa} - 24567.615 \cdot \mathrm{GQ}_{Gd} - 12473.781 \cdot \mathrm{GQ}_{None} - 39850.791 \cdot \mathrm{GQ}_{Po} \\
&- 22132.007 \cdot \mathrm{GQ}_{TA} - 99107.878 \cdot \mathrm{GC2}_{Ex} + 19877.064 \cdot \mathrm{GC2}_{Fa} + 22142.440 \cdot \mathrm{GC2}_{Gd} \\
&- 12473.781 \cdot \mathrm{GC2}_{None} + 24264.197 \cdot \mathrm{GC2}_{Po} + 22759.832 \cdot \mathrm{GC2}_{TA} - 6094.157 \cdot \mathrm{PD}_{N} \\
&- 9826.090 \cdot \mathrm{PD}_{P} - 6617.861 \cdot \mathrm{PD}_{Y} + 12841.810 \cdot \mathrm{PQ}_{Ex} - 152413.113 \cdot \mathrm{PQ}_{Fa} \\
&- 123577.893 \cdot \mathrm{PQ}_{Gd} + 240611.086 \cdot \mathrm{PQ}_{None} - 10638.804 \cdot \mathrm{FC}_{GdPrv} - 2444.082 \cdot \mathrm{FC}_{GdWo} \\
&- 965.273 \cdot \mathrm{FC}_{MnPrv} - 6761.129 \cdot \mathrm{FC}_{MnWw} - 1728.830 \cdot \mathrm{FC}_{None} - 14835.697 \cdot \mathrm{MF}_{Gar2} \\
&- 13449.858 \cdot \mathrm{MF}_{None} + 4994.335 \cdot \mathrm{MF}_{Othr} - 11138.853 \cdot \mathrm{MF}_{Shed} + 11891.981 \cdot \mathrm{MF}_{TenC} \\
&- 12372.785 \cdot \mathrm{STP}_{COD} + 3115.062 \cdot \mathrm{STP}_{CWD} + 12798.396 \cdot \mathrm{STP}_{Con} + 3681.960 \cdot \mathrm{STP}_{ConLD} \\
&- 8896.450 \cdot \mathrm{STP}_{ConLI} - 10695.479 \cdot \mathrm{STP}_{ConLw} + 8008.159 \cdot \mathrm{STP}_{New} - 5307.202 \cdot \mathrm{STP}_{Oth} \\
&- 12869.768 \cdot \mathrm{STP}_{WD} - 6733.405 \cdot \mathrm{SC}_{Abnorml} + 2939.844 \cdot \mathrm{SC}_{AdjLand} - 6946.777 \cdot \mathrm{SC}_{Alloca}
\end{aligned}
$$

$$- 5656.828 \cdot \mathrm{SC}_{Family} + 50.010 \cdot \mathrm{SC}_{Normal} - 6190.968 \cdot \mathrm{SC}_{Partial} \tag{2}$$

Đánh giá sai số: MAE trên tập kiểm tra: **9,772.71**.
Nhận xét: Mô hình này đạt mức sai số thấp nhất trên tập test so với mô hình 2b và 2c. Tuy nhiên, việc sử dụng quá nhiều đặc trưng dẫn đến nguy cơ **Overfitting** (Quá khớp) cao. Mô hình có xu hướng "học thuộc lòng"nhiễu của dữ liệu huấn luyện thay vì học quy luật tổng quát. Mặc dù kết quả trên tập test này rất tốt, nhưng mô hình sẽ rất nhạy cảm và kém ổn định nếu dữ liệu đầu vào có sự thay đổi nhỏ.

5.2 Yêu cầu 2b: Mô hình với đặc trưng đơn lẻ tốt nhất

Tiếp cận: Đánh giá độc lập 5 đặc trưng tốt nhất đã chọn ở phần EDA (`OverallQual`, `GrLivArea`, `TotalBsmtSF`, `GarageCars`, `1stFlrSF`) bằng 5-Fold CV.
Kết quả K-Fold Cross-Validation (MAE trung bình):

- `OverallQual`: 33,814.43
- `GrLivArea`: 37,797.67
- `GarageCars`: 42,630.25
- `1stFlrSF`: 46,462.11
- `TotalBsmtSF`: 46,523.12

`OverallQual` (Chất lượng tổng thể) đạt giá trị MAE trung bình thấp nhất, do đó được chọn làm đặc trưng duy nhất để huấn luyện mô hình cơ sở (Baseline model).
Nhận xét:

- **Ưu điểm:** Mô hình cực kỳ đơn giản (chỉ có 1 biến và 1 hệ số chặn), tránh hoàn toàn Overfitting.
- **Nhược điểm:** Underfitting (Chưa khớp). Bỏ lỡ rất nhiều thông tin quý giá như diện tích hay vị trí ngôi nhà, dẫn đến MAE vẫn còn khá cao.

Công thức hồi quy (với đặc trưng `OverallQual`) trên tập test:

$$\mathrm{SalePrice} = \theta_0 + \theta_1 \cdot \mathrm{OQ} \tag{3}$$

Trong đó, giá trị cụ thể thu được từ thực nghiệm:

$$\mathrm{SalePrice} = -96206.079 + 45435.802 \cdot \mathrm{OQ} \tag{4}$$

Đánh giá sai số: MAE của mô hình tốt nhất (`OverallQual`): **30,903.31**.
Nhận xét (Underfitting): Các mô hình đơn biến đều gặp hiện tượng **Underfitting** (Chưa khớp). Sai số MAE ở mức cao (>30,000) cho thấy một đặc trưng đơn lẻ không đủ sức mạnh để giải thích sự biến động phức tạp của giá nhà. Mô hình quá đơn giản để nắm bắt các quy luật của dữ liệu.

5.3 Yêu cầu 2c: Kỹ thuật thiết kế đặc trưng (Feature Engineering)

Để nâng cao hiệu suất và giải quyết các vấn đề phát hiện từ khâu EDA (lệch phải, phi tuyến, đa cộng tuyến), 3 phương án kiến trúc dữ liệu đã được thiết kế và so sánh qua 5-Fold CV.

5.3.1 Phương án 1: Biến đổi Logarit (Log Transformation)

Kỹ thuật: Áp dụng hàm $\ln(1 + x)$ lên các biến diện tích có phân phối lệch phải.

- **Nhận xét ưu điểm:** Khắc phục vấn đề phân phối lệch phải (quan sát được ở Hình 1). Nén thang đo dữ liệu, triệt tiêu sự lấn át của các giá trị ngoại lai.
- **Nhận xét nhược điểm:** Khó diễn giải hệ số θ. Quan hệ trở thành Log-Linear thay vì Linear tuyến tính thông thường.

5.3.2 Phương án 2: Tổng hợp Đặc trưng (Domain Knowledge)

Kỹ thuật: Gom nhóm các biến có chung lớp ý nghĩa thực tế để tạo ra siêu đặc trưng (Super Features):

- `Total_Home_Qual` = `OverallQual` + `OverallCond`
- `Total_Square_Feet` = `GrLivArea` + `TotalBsmtSF`
- `Total_Bathrooms` = `FullBath` + `BsmtFullBath` + 0.5× (`HalfBath` + `BsmtHalfBath`)
- `House_Age` = `YrSold` - `YearBuilt`
- **Nhận xét ưu điểm:** Khắc phục hoàn toàn hiện tượng đa cộng tuyến phát hiện ở Heatmap (Hình 2). Hệ số mang ý nghĩa thực tiễn rất cao (ví dụ: Hệ số của `House_Age` âm phản ánh sự rớt giá theo thời gian).
- **Nhận xét nhược điểm:** Xảy ra mất mát thông tin (Information Loss) nhẹ khi đánh đồng giá trị của không gian hầm và không gian mặt đất vào chung một biến diện tích.

5.3.3 Phương án 3: Tương tác và Phi tuyến (Polynomial)

Kỹ thuật: Mở rộng không gian đặc trưng bằng phép nhân chéo (`OverallQual` × `GrLivArea`) và bình phương (`OverallQual`^{2}).

- **Nhận xét ưu điểm:** Khắc phục chính xác hiện tượng phi tuyến tính phát hiện ở đồ thị Chất lượng - Giá nhà (Hình 4). Cho phép mô hình tuyến tính mô phỏng được sự tăng vọt giá trị ở các điểm chất lượng cao.
- **Nhận xét nhược điểm:** Nguy cơ Overfitting cao. Dễ đẩy ma trận $X^T X$ vào trạng thái suy biến do độ tương quan mạnh giữa x và x^2.

Kết quả đánh giá 3 phương án (K-Fold CV MAE):

- Phương án 1 (Biến đổi Logarit): 26,937.96

- Phương án 2 (Tổng hợp đặc trưng): **24,605.68**
- Phương án 3 (Tương tác & Đa thức): 24,711.45

Kết luận lựa chọn: Qua kết quả đánh giá K-Fold CV, **Phương án 2 (Tổng hợp Đặc trưng)** được lựa chọn để huấn luyện lại trên toàn bộ tập dữ liệu, do đạt được sự cân bằng tối ưu giữa việc giảm MAE, tốc độ tính toán và khả năng giải thích.
Công thức hồi quy chi tiết:

$$\begin{aligned}\text{SalePrice} = &-100819.781 + 13056.402 \cdot \text{Total_Home_Qual} \\ &+ 48.875 \cdot \text{Total_Square_Feet} + 11663.461 \cdot \text{Total_Bathrooms} \\ &- 608.016 \cdot \text{House_Age}\end{aligned} \tag{5}$$

Đánh giá sai số (Phương án 2):

- MAE CV (Tập huấn luyện): **24,605.68**
- MAE Validation (Tập test): **21,621.00**

Nhận xét về tính ổn định: Phương án 2 cho thấy sự cân bằng rất tốt. Đặc biệt, giá trị MAE trên tập test (21,621.00) thấp hơn so với MAE trung bình khi CV (24,605.68). Điều này chứng tỏ mô hình **không bị Overfitting**, có khả năng khái quát hóa (Generalization) cực kỳ tốt trên dữ liệu mới. Việc tổng hợp các biến giúp loại bỏ nhiễu và tập trung vào những tín hiệu thực sự ảnh hưởng đến giá trị bất động sản.

6 Kết luận Tổng thể

Bài tập đã hoàn thành xuất sắc việc xây dựng đường ống (pipeline) học máy từ xâu chuỗi dữ liệu thô, phân tích khám phá (EDA) qua biểu đồ, cho đến việc triển khai toán học mô hình Hồi quy tuyến tính bằng Normal Equation. Việc kết hợp quan sát từ EDA vào thiết kế Feature Engineering chứng tỏ sự thấu hiểu dữ liệu đóng vai trò quyết định trong việc tối ưu hóa hiệu năng mô hình.